有据：A股年报问答

项目用途与使用示例

项目用公开年报和公告回答上市公司相关问题。用户在网页输入问题，回答中附上原文摘录和 PDF 页码，可以继续打开原文件核对。目前整理了 20 家公司的 60 份文档，共 5,364 页。

实现分为三部分：员工人数走检索与生成，财务和公告从审核目录读取字段，股价与 K 线交给独立行情接口。三类问题共用一个聊天页面，支持追问和历史会话。

可以查询什么

类型	示例问题	处理方式
员工	中国神华2025年在职员工数量合计是多少人？	检索年报后生成草稿，附引用
财务	宁德时代2025年营业收入是多少？	目录取值；代码计算同比与换算
行情	贵州茅台最新股价、PE、PB和市值是多少？	查询行情源，显示数据时间

一个保存的回答示例

问题：宁德时代2025年营业收入是多少？
回答：423,701,834 千元。
来源：《2025年年度报告》，PDF 物理第 11 页。

这条回答直接读取审核目录，没有调用生成模型。字段同时记录指标行、年度列、原值和单位。点击引用可以查看原文，再跳转到 PDF 对应页。

示例为已保存的字段结果，金额沿用报告原单位。

在线体验

Demo：https://headwear-caliber-demanding.ngrok-free.dev/

代码：https://github.com/akr1a-wzy/RAG-Demo

Demo 无需登录。所有访客共享每日 50 次问答尝试，北京时间零点刷新；连续 60 秒最多 20 次 API 写请求。本机和 ngrok 隧道须保持运行。

实现流程

共享查询理解，分别执行检索、字段查询与行情

财务与行情先共用查询理解层，规范化别名和短年份，恢复受限的相邻追问，保留未知限定，再检查能力范围。总营收按营业收入口径明示；营业总收入是独立未核准指标。

员工问答

先从当前问题和历史消息中识别公司、报告期和主体，再执行 BM25 与 BGE 向量召回，用 RRF 合并结果。针对员工合计等字段补充检索后，交给 Cross-Encoder 重排，每任务从 20 个候选中取 Top5。

DeepSeek 根据检索结果生成回答，后续检查所引用的事实、年份、单位和来源。员工回答仍标为草稿；公司或期间不清楚时先询问，缺少受支持事实时展示证据或拒答。

流程：问题与历史 → 公司/期间识别 → 混合检索 → 重排 → 生成 → 引用与事实检查

财务与公告

财务和公告问题使用单独的字段目录。目前收录 320 条财务比较事实和 83 条公告相关事实。目录中的记录与原 PDF、坐标和审核证据关联，查询时读取数值，使用 Decimal 计算换算、同比和差额。

这部分不调用 LLM。2024 年数值来自 2025 年报的比较列，调整或重述口径随字段保留。目录外的指标和未支持的限定条件不能按普通字段查询。

行情与网页

行情接口提供最新报价和前复权日 K 线，返回来源、业务时间与获取时间。快照只在用户手动选择回放时使用，并标为非实时。网页由 FastAPI 提供，SQLite 保存基本会话历史，公网入口支持可选认证、同源检查和持久化请求额度。

代码位置

模块	主要内容
src/app/retrieval/	PDF 解析、切分、BGE 向量、Chroma、混合检索与重排
src/app/qa/	LangGraph 问答流程、字段目录、计算、事实和引用检查
src/app/market/	行情意图、接口、日 K 线与快照
src/app/web/	API、会话存储、认证与前端静态文件

开发中遇到的问题

从具体失败定位原因，再检查修复引入的回归

1. 补回营收来源页，却把关联财务公司表排在首位

中国神华营收题的正确第 8 页最初未进 20 个候选，扩到 50 个仍未入 Top 5。增加财务摘要补召回后，指定页已命中，首位却是第 124 页关联财务公司（控股股东的子公司）收入 4,251 百万元，上市主体应为 294,916 百万元。当时尚未生成回答。

根因是任意子串“主要财务指标”匹配。改为独立标题边界并排除财务公司子表、季度表后，正确第 8 页升至首位。扩大候选只能帮助诊断，报告所属公司也不能代替表内主体识别。这道已见题保留为回归，不据此宣称全量主体识别通过。

代码：retrieval/query_tasks.py；证据：神华补召回前后 Top 5 与主体反例。

2. 数字在原文中，年度和单位仍可能错配

早期校验只检查数字出现性：合成表中 2025 年为 200、2024 年为 100，写成“2025 年为 100”仍能通过。真实解析中也发现前一表“万元”污染局部“元”的情况。

补充指标行、年度列、数值、局部单位与主体绑定，选定财务字段保存 PDF 哈希、坐标和审核图。绑定回归 33/33 含 30 个合成用例和 3 个真实来源重建陈述；403 项后续证据检查仅覆盖选定字段。复杂跨页表头仍有风险，因此财务只开放审核目录。

代码：qa/facts.py、qa/catalog.py；验证范围不等于全语料表格语义。

3. 同一问法在不同路线中丢失条件

“宁德时代25年股价最高是多少”曾误返最新价，追问“问的是最高”又进入文档；财务的“总营收”“25年”则因别名和年份残留被拒。分支各自解析，局部补词无法保持一致。

改为共享查询理解，保留别名、年度、相邻追问和未知限定，在取数前校验能力。已知场景本机 16/16、公网 6/6，0 次生成；总营收按营业收入口径明示。确定性规则可追踪、无新增理解模型调用，但表达覆盖有限；年度最高/最低价仍明确不支持。

代码：qa/query_understanding.py、market/service.py；路径均相对 src/app/。

测试与运行

结果来自本地开发环境，记录截至2026年11月3日

检查	结果	范围
指定来源页 Recall@5	93.33%	v4 的 30 道可回答题，取各题召回率平均值
全部来源页找齐	26/30	同一批检索题；另外 5 道拒答未在该阶段评分
已知业务回归	85/85	财务、公告、员工、计算、边界和追问
完整 pytest	607 项通过	2026-11-03 原开发环境历史记录；非公开 CI

Recall 不是答案准确率。85 道业务用例及事实已在开发中见过，由同一助手编制和审核。另有 403 项选定事实证据检查，没有覆盖全语料表格语义。原报告摘要与 SHA256 在仓库 review/metrics.json，原始评测数据与报告未随仓库公开。

尚未解决的问题

复杂表头、跨页表格和单位关联仍需继续处理；员工生成回答需要结合引用核对。查询理解仅覆盖有限规则，未知表达可能保守拒答。年度最高价、最低价，以及 LangGraph 节点级断点恢复尚未实现。本轮同步材料，没有重跑封存验收。

本地运行条件

原环境为 Windows、Python 3.11 和 NVIDIA GPU，依赖由 uv.lock 固定。在输入准备完整的环境中安装依赖并启动：

```
uv sync --extra gpu --locked
.\Start-LocalDemo.ps1
```

本地默认地址：http://127.0.0.1:8000

公开源码不含密钥、会话、原始 PDF、模型、索引和审核目录。完整服务依赖这些文件，克隆后还不能直接启动。仓库 tools/check_source.py 可以独立检查文件哈希和 Python 语法；数据准备情况见 docs/reproduction.md。

入口与材料

GitHub：https://github.com/akr1a-wzy/RAG-Demo

项目页：https://headwear-caliber-demanding.ngrok-free.dev/static/project.html

项目页提供 Demo 和源码阅读包。问答进入业务处理后，拒答或失败仍计额度；超限返回 429，稍后或次日再试。重启不清零，浏览与下载不计上述额度。